# Olist: Barplots y Pie Charts

## Ejercicios de visualización con Pandas y Matplotlib

En esta nota trabajamos con el dataset de Olist para practicar gráficas de barras (barplots) y gráficas de pastel (pie charts).

Antes de cada gráfica seguimos el mismo orden:

1. **Primero la pregunta**: ¿qué queremos saber?
2. **Después los datos**: ¿qué variables necesitamos y qué operación hacemos sobre ellas?
3. **Finalmente, la gráfica**: ¿qué tipo de gráfica representa mejor el resultado?

> Los CSV de Olist se cargan desde la carpeta `datos_olist_reales`. Si no la encuentra, abre esta nota desde `examen_olist` o ajusta la variable `carpeta`.

# Preparación: librerías y datos

In [33]:
```
import pandas as pd
from pathlib import Path
import matplotlib.pyplot as plt

# Los CSV originales de Olist están junto a esta nota.
opciones = [
    Path.cwd() / "datos_olist_reales",
    Path.cwd() / "estudio_pandas" / "examen_olist" / "datos_olist_reales",
    Path.cwd().parent / "datos_olist_reales",
]
carpeta = next((p for p in opciones if (p /
"olist_orders_dataset.csv").is_file()), None)
if carpeta is None:
    raise FileNotFoundError(
        "No encuentro datos_olist_reales. Abre esta nota desde examen_olist "
        "o ajusta la variable carpeta a su ubicación."
    )

orders = pd.read_csv(carpeta / "olist_orders_dataset.csv")
customers = pd.read_csv(carpeta / "olist_customers_dataset.csv")
order_items = pd.read_csv(carpeta / "olist_order_items_dataset.csv")
products = pd.read_csv(carpeta / "olist_products_dataset.csv")
sellers = pd.read_csv(carpeta / "olist_sellers_dataset.csv")
order_payments = pd.read_csv(carpeta / "olist_order_payments_dataset.csv")
order_reviews = pd.read_csv(carpeta / "olist_order_reviews_dataset.csv")
translation = pd.read_csv(carpeta / "product_category_name_translation.csv")
```

In [34]:
```
products.head()
```

Out[34]:

| | product_id | product_category_name | product_name_lenght | product_description_lenght | product_photos_qty | product_weight_g | product_length_cm | product_height_cm | product_width_cm |
|---|---|---|---|---|---|---|---|---|---|
| 0 | 1e9e8ef04dbcff4541ed26657ea517e5 | perfumaria | 40.0 | 287.0 | 1.0 | 225.0 | 16.0 | 10.0 | 14.0 |
| 1 | 3aa071139cb16b67ca9e5dea641aaa2f | artes | 44.0 | 276.0 | 1.0 | 1000.0 | 30.0 | 18.0 | 20.0 |
| 2 | 96bd76ec8810374ed1b65e291975717f | esporte_lazer | 46.0 | 250.0 | 1.0 | 154.0 | 18.0 | 9.0 | 15.0 |
| 3 | cef67bcfe19066a932b7673e239eb23d | bebes | 27.0 | 261.0 | 1.0 | 371.0 | 26.0 | 4.0 | 26.0 |
| 4 | 9dc1a7de274444849c219cff195d0b71 | utilidades_domesticas | 37.0 | 402.0 | 4.0 | 625.0 | 20.0 | 17.0 | 13.0 |

In [35]:
```
customers.head()
```

Out[35]:

| | customer_id | customer_unique_id | customer_zip_code_prefix | customer_city | customer_state |
|---|---|---|---|---|---|
| 0 | 06b8999e2fba1a1fbc88172c00ba8bc7 | 861eff4711a542e4b93843c6dd7febb0 | 14409 | franca | SP |
| 1 | 18955e83d337fd6b2def6b18a428ac77 | 290c77bc529b7ac935b93aa66c333dc3 | 9790 | sao bernardo do campo | SP |
| 2 | 4e7b3e00288586ebd08712fdd0374a03 | 060e732b5b29e8181a18229c7b0b2b5e | 1151 | sao paulo | SP |
| 3 | b2b6027bc5c5109e529d4dc6358b12c3 | 259dac757896d24d7702b9acbbff3f3c | 8775 | mogi das cruzes | SP |
| 4 | 4f2d8ab171c80ec8364f7c12e35b23ad | 345ecd01c38d18a9036ed96c73b8d066 | 13056 | campinas | SP |

In [36]:
```
order_payments.head()
```

Out[36]:

| | order_id | payment_sequential | payment_type | payment_installments | payment_value |
|---|---|---|---|---|---|
| 0 | b81ef226f3fe1789b1e8b2acac839d17 | 1 | credit_card | 8 | 99.33 |
| 1 | a9810da82917af2d9aefd1278f1dcfa0 | 1 | credit_card | 1 | 24.39 |
| 2 | 25e8ea4e93396b6fa0d3dd708e76c1bd | 1 | credit_card | 1 | 65.71 |
| 3 | ba78997921bbcdc1373bb41e913ab953 | 1 | credit_card | 8 | 107.78 |
| 4 | 42fdf880ba16b47b59251dd489d4441a | 1 | credit_card | 2 | 128.45 |

## Colores que usaremos en las gráficas

Definimos los colores una sola vez para que todas las gráficas se vean parecidas. El gris se reserva para la categoría `"Otros"` de los pie charts.

In [37]:
```
color_barras = "#2a78d6"
color_barras_secundario = "#eb6834"
colores_pie_con_otros = ["#2a78d6", "#eb6834", "#1baf7a", "#eda100", "#e87ba4",
"#c3c2b7"]
colores_metodos_pago = ["#2a78d6", "#eb6834", "#1baf7a", "#eda100", "#e87ba4"]
```

---

# Ejercicio 1: Categorías de productos

**Pregunta:** ¿Qué categorías tienen mayor presencia en el catálogo de Olist?

In [38]:
```
cantidad_productos_por_categoria =
products["product_category_name"].value_counts()
cantidad_productos_por_categoria =
cantidad_productos_por_categoria.sort_values(ascending=False)

print("Número de categorías:", len(cantidad_productos_por_categoria))
cantidad_productos_por_categoria
```

```
Número de categorías: 73
```

Out[38]:

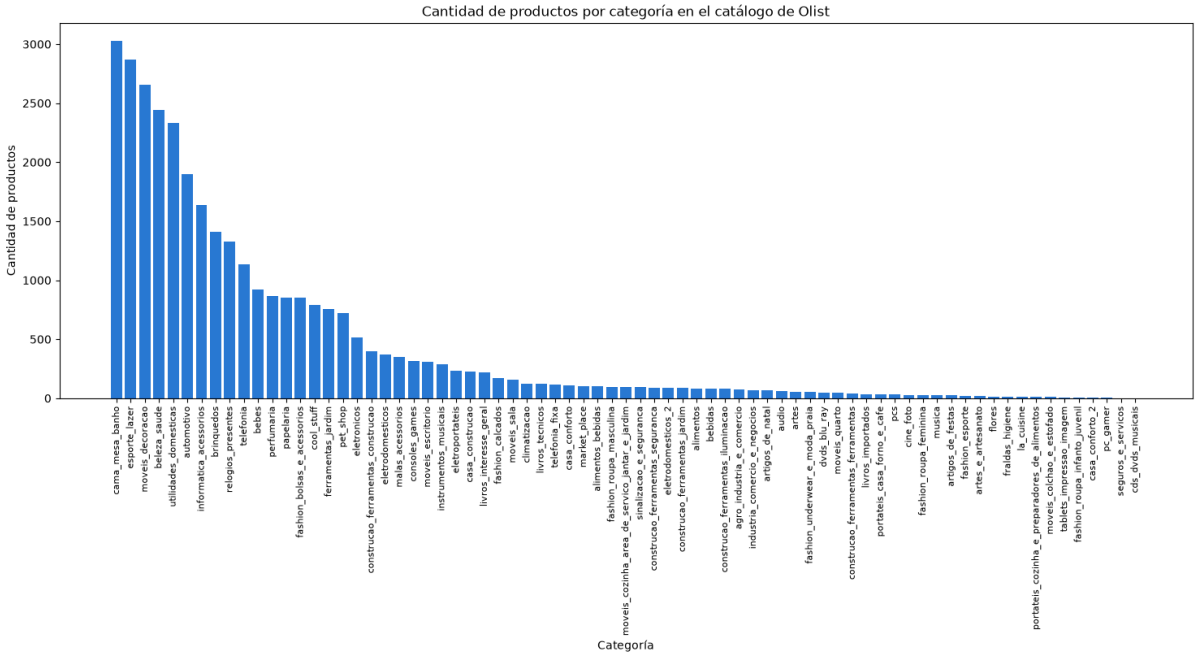
```
product_category_name
cama_mesa_banho                   3029
esporte_lazer                     2867
moveis_decoracao                  2657
beleza_saude                      2444
utilidades_domesticas             2335
                                  ...
fashion_roupa_infanto_juvenil        5
casa_conforto_2                      5
pc_gamer                             3
seguros_e_servicos                   2
cds_dvds_musicais                    1
Name: count, Length: 73, dtype: int64
```

In [39]:
```
fig, ax = plt.subplots(figsize=(18, 6))

ax.bar(cantidad_productos_por_categoria.index,
cantidad_productos_por_categoria.values, color=color_barras)

ax.set_title("Cantidad de productos por categoría en el catálogo de Olist")
ax.set_xlabel("Categoría")
ax.set_ylabel("Cantidad de productos")
plt.xticks(rotation=90, fontsize=8)

plt.show()
```




---

# Ejercicio 2: Las 10 categorías principales

**Pregunta:** ¿Cuáles son las categorías que tienen mayor presencia en el catálogo?

- **Gráfica:** barras horizontales, porque los nombres de las categorías son largos y se leen mejor en el eje vertical.

In [40]:
```
top_10_categorias = cantidad_productos_por_categoria.head(10)
top_10_categorias
```

Out[40]:
```
product_category_name
cama_mesa_banho           3029
esporte_lazer             2867
moveis_decoracao          2657
beleza_saude              2444
utilidades_domesticas     2335
automotivo                1900
informatica_acessorios    1639
brinquedos                1411
relogios_presentes        1329
telefonia                 1134
Name: count, dtype: int64
```

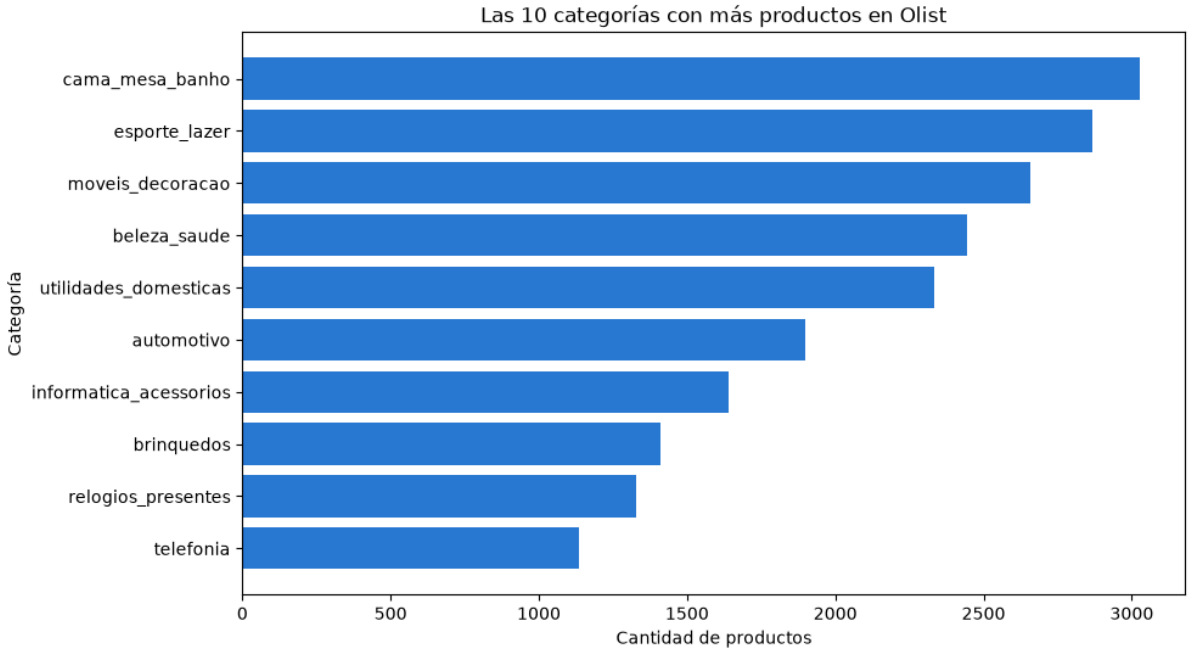
En una gráfica de barras horizontales matplotlib dibuja el primer valor abajo. Usamos `ax.invert_yaxis()` para que la categoría con más productos quede arriba.

In [41]:
```
fig, ax = plt.subplots(figsize=(10, 6))

ax.barh(top_10_categorias.index, top_10_categorias.values, color=color_barras)
ax.invert_yaxis()

ax.set_title("Las 10 categorías con más productos en Olist")
ax.set_xlabel("Cantidad de productos")
ax.set_ylabel("Categoría")

plt.show()
```



---

# Ejercicio 3: Distribución de productos

**Pregunta:** ¿Qué proporción del catálogo está concentrada en las principales categorías?

- **Gráfica:** pie chart, porque queremos ver qué parte del total representa cada grupo.

In [42]:
```
top_5_categorias = cantidad_productos_por_categoria.head(5)
cantidad_productos_otras_categorias =
cantidad_productos_por_categoria.iloc[5:].sum()

distribucion_productos = top_5_categorias.copy()
distribucion_productos["Otros"] = cantidad_productos_otras_categorias

distribucion_productos
```

Out[42]:
```
product_category_name
cama_mesa_banho           3029
esporte_lazer             2867
moveis_decoracao          2657
beleza_saude              2444
utilidades_domesticas     2335
Otros                    19009
Name: count, dtype: int64
```

In [43]:
```
porcentaje_productos_top_5 = top_5_categorias.sum() /
cantidad_productos_por_categoria.sum() * 100
print("Porcentaje del catálogo en las 5 categorías principales:",
round(porcentaje_productos_top_5, 1), "%")
```

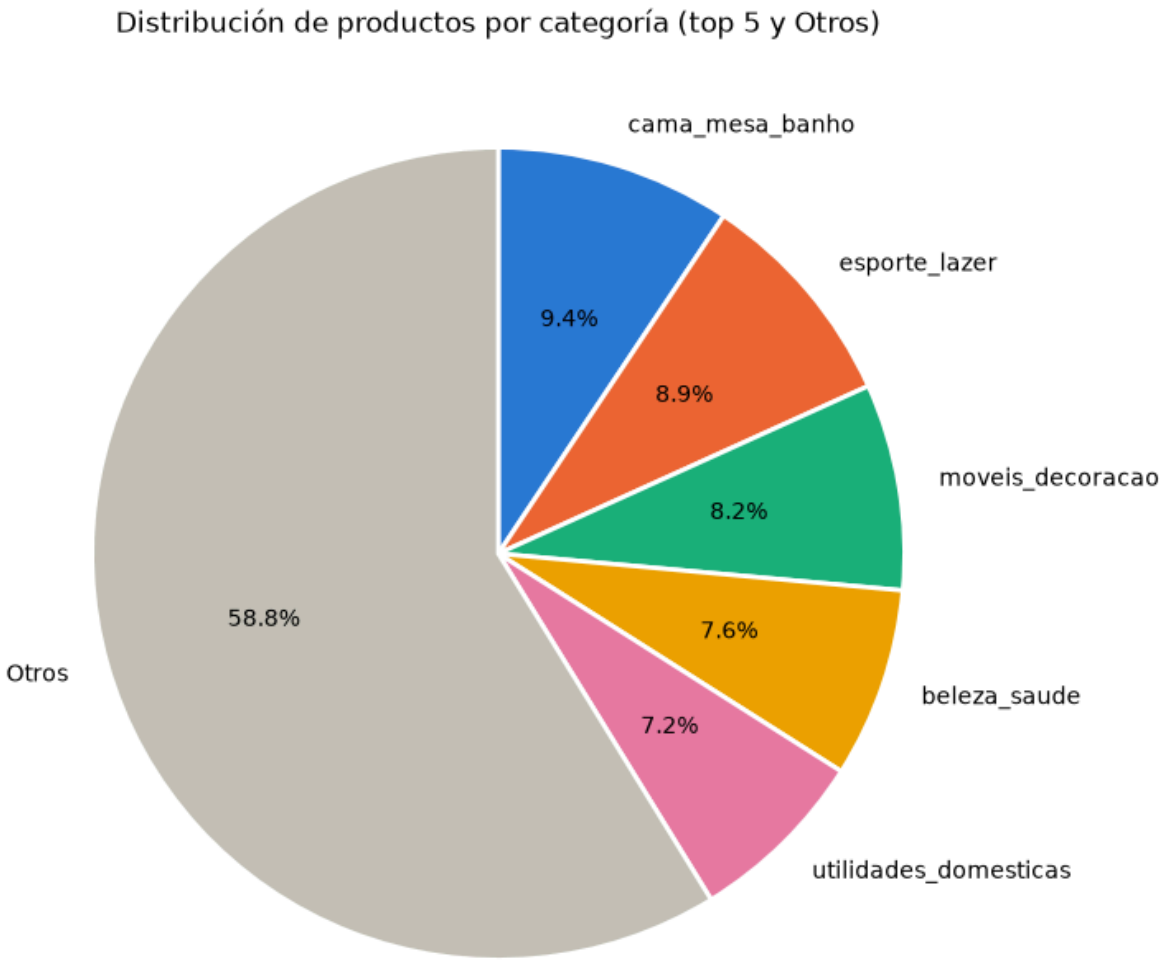
```
Porcentaje del catálogo en las 5 categorías principales: 41.2 %
```

In [44]:
```
fig, ax = plt.subplots(figsize=(8, 8))

ax.pie(
    distribucion_productos.values,
    labels=distribucion_productos.index,
    autopct="%1.1f%%",
    colors=colores_pie_con_otros,
    startangle=90,
    counterclock=False,
    wedgeprops={"edgecolor": "white", "linewidth": 2}
)

ax.set_title("Distribución de productos por categoría (top 5 y Otros)")

plt.show()
```



---

# Ejercicio 4: Clientes por estado

**Pregunta:** ¿Qué estados concentran la mayor cantidad de clientes?

In [45]:
```
print("Registros en la tabla de clientes:", len(customers))

clientes_unicos = customers.drop_duplicates(subset="customer_unique_id")
print("Clientes únicos:", len(clientes_unicos))
```

```
Registros en la tabla de clientes: 99441
Clientes únicos: 96096
```

In [46]:
```
cantidad_clientes_por_estado = clientes_unicos["customer_state"].value_counts()
cantidad_clientes_por_estado =
cantidad_clientes_por_estado.sort_values(ascending=False)

print("Número de estados:", len(cantidad_clientes_por_estado))
cantidad_clientes_por_estado
```

```
Número de estados: 27
```

Out[46]:

| customer_state | |
|---|---|
| SP | 40295 |
| RJ | 12377 |
| MG | 11255 |
| RS | 5277 |
| PR | 4882 |
| SC | 3529 |
| BA | 3276 |
| DF | 2073 |
| ES | 1963 |
| GO | 1951 |
| PE | 1604 |
| CE | 1311 |
| PA | 949 |
| MT | 875 |
| MA | 725 |
| MS | 693 |
| PB | 519 |
| PI | 482 |
| RN | 474 |
| AL | 401 |
| SE | 341 |
| TO | 273 |
| RO | 239 |
| AM | 143 |
| AC | 77 |
| AP | 67 |
| RR | 45 |

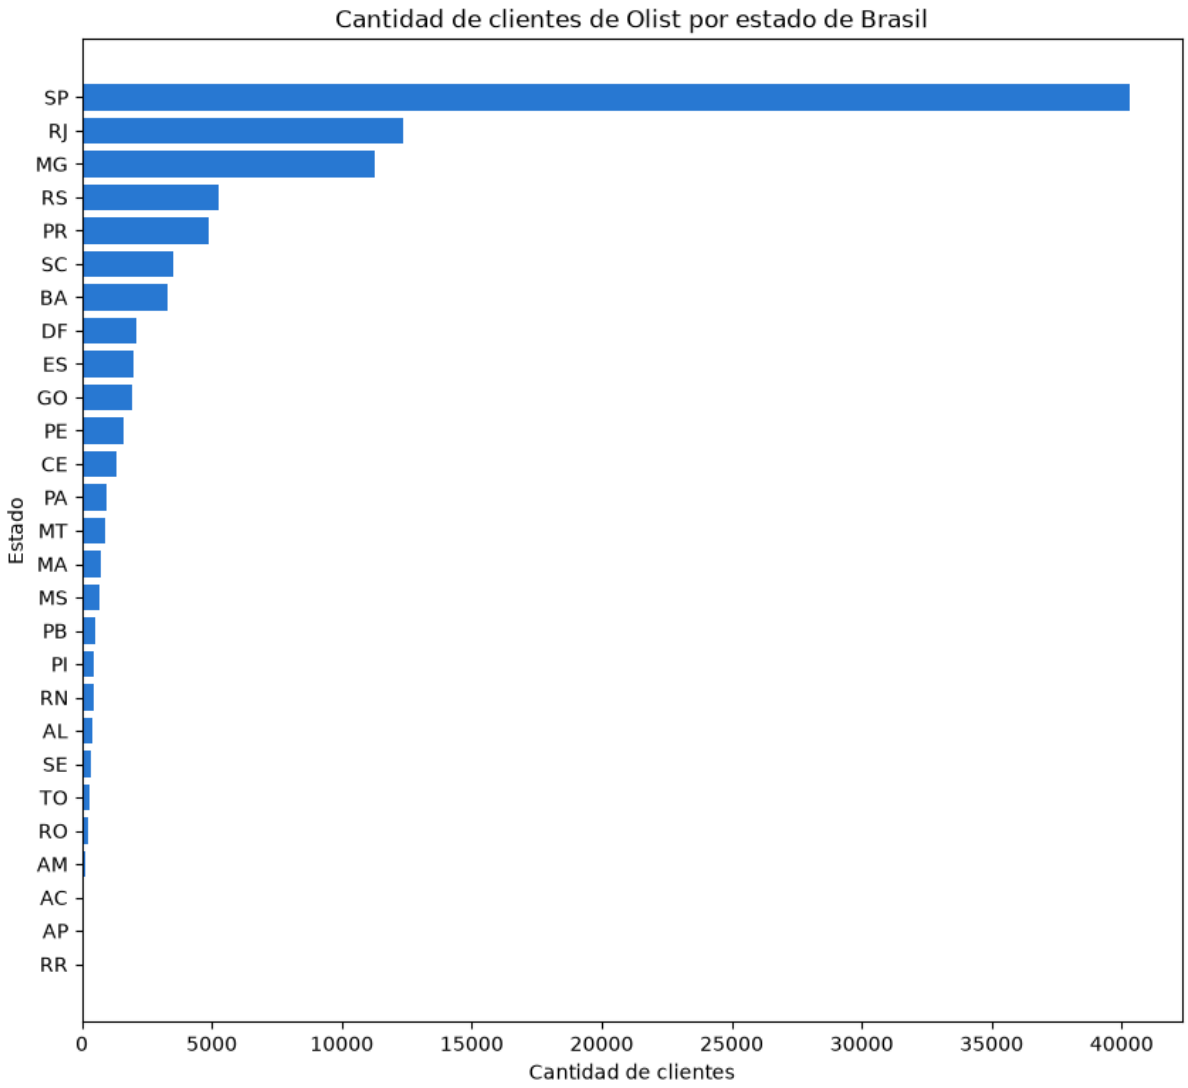
Name: count, dtype: int64

In [47]:
```
fig, ax = plt.subplots(figsize=(10, 9))

ax.barh(cantidad_clientes_por_estado.index, cantidad_clientes_por_estado.values,
color=color_barras)
ax.invert_yaxis()

ax.set_title("Cantidad de clientes de Olist por estado de Brasil")
ax.set_xlabel("Cantidad de clientes")
ax.set_ylabel("Estado")

plt.show()
```




---

# Ejercicio 5: Estados principales

**Pregunta:** ¿Qué tan concentrada está la base de clientes geográficamente?

In [48]:
```
top_5_estados = cantidad_clientes_por_estado.head(5)
cantidad_clientes_otros_estados = cantidad_clientes_por_estado.iloc[5:].sum()

distribucion_clientes = top_5_estados.copy()
distribucion_clientes["Otros"] = cantidad_clientes_otros_estados

distribucion_clientes
```

Out[48]:
```
customer_state
SP       40295
RJ       12377
MG       11255
RS        5277
PR        4882
Otros    22010
Name: count, dtype: int64
```

In [49]:
```
porcentaje_clientes_top_5 = top_5_estados.sum() /
cantidad_clientes_por_estado.sum() * 100
print("Porcentaje de clientes en los 5 estados principales:",
round(porcentaje_clientes_top_5, 1), "%")
```

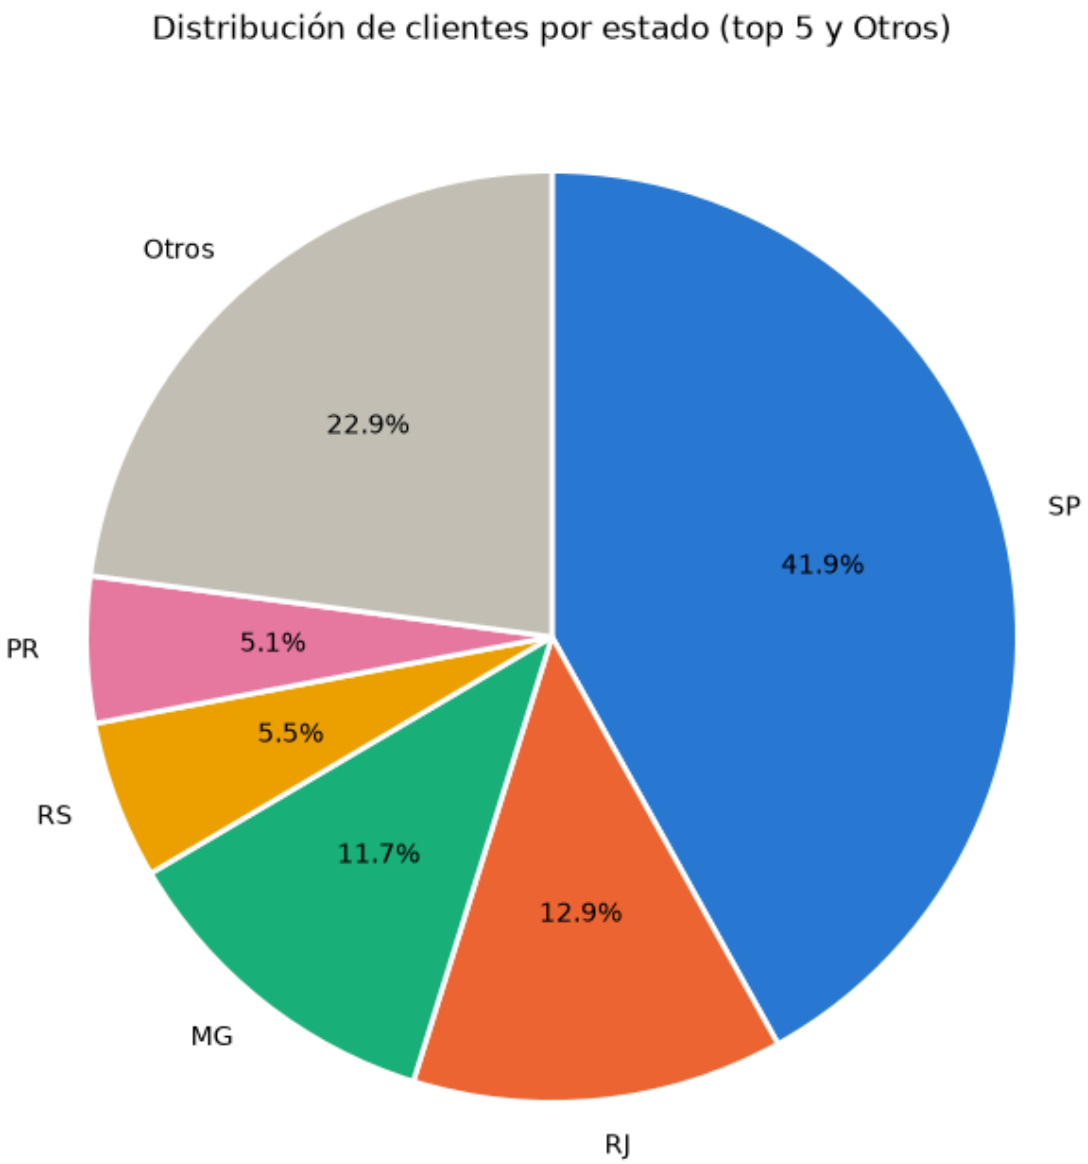
```
Porcentaje de clientes en los 5 estados principales: 77.1 %
```

In [50]:
```
fig, ax = plt.subplots(figsize=(8, 8))

ax.pie(
    distribucion_clientes.values,
    labels=distribucion_clientes.index,
    autopct="%1.1f%%",
    colors=colores_pie_con_otros,
    startangle=90,
    counterclock=False,
    wedgeprops={"edgecolor": "white", "linewidth": 2}
)

ax.set_title("Distribución de clientes por estado (top 5 y Otros)")

plt.show()
```



## Ejercicio 6: Métodos de pago

**Pregunta:** ¿Cuál es el método de pago más utilizado?

In [51]:
```
cantidad_pagos_por_metodo = order_payments["payment_type"].value_counts()
cantidad_pagos_por_metodo =
cantidad_pagos_por_metodo.sort_values(ascending=False)

cantidad_pagos_por_metodo
```

Out[51]:
```
payment_type
credit_card     76795
boleto          19784
voucher          5775
debit_card       1529
not_defined         3
Name: count, dtype: int64
```

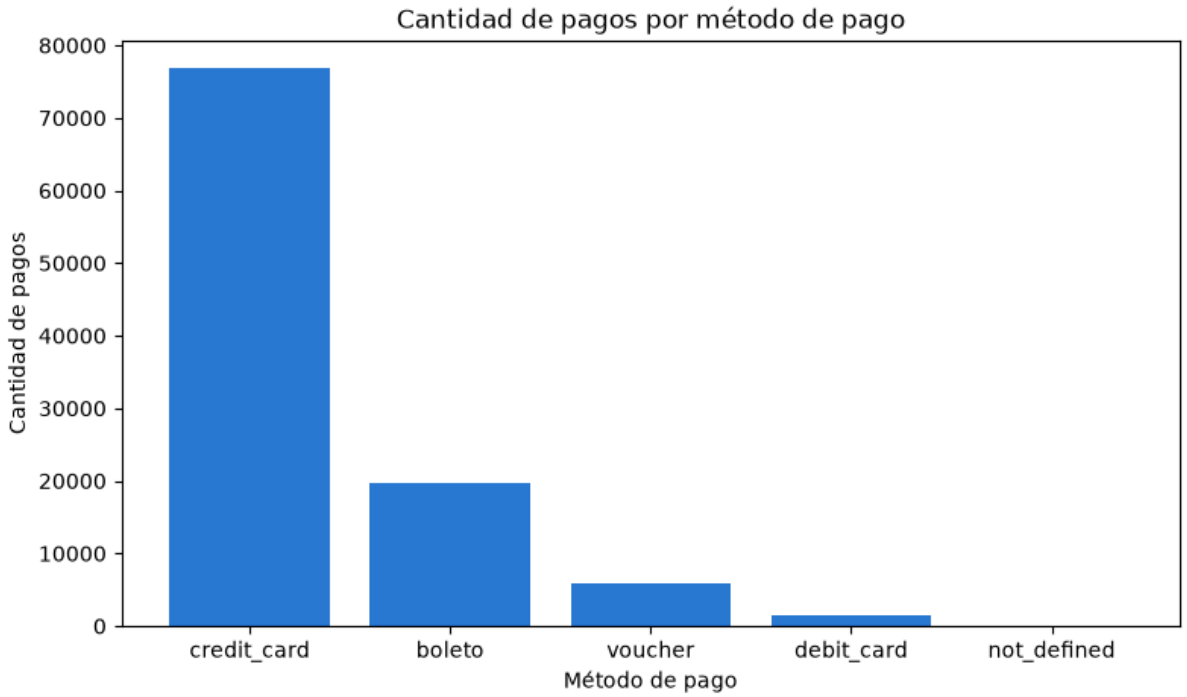
## Gráfica de barras

In [52]:
```
fig, ax = plt.subplots(figsize=(9, 5))

ax.bar(cantidad_pagos_por_metodo.index, cantidad_pagos_por_metodo.values,
color=color_barras)

ax.set_title("Cantidad de pagos por método de pago")
ax.set_xlabel("Método de pago")
ax.set_ylabel("Cantidad de pagos")

plt.show()
```




## Pie chart

Algunos métodos de pago tienen porcentajes muy pequeños y sus textos se encimarían. Por eso hacemos una función que solo muestra el porcentaje cuando es de 1% o más, colocamos los porcentajes afuera del pastel con `pctdistance` y ponemos los nombres de los métodos en una leyenda.

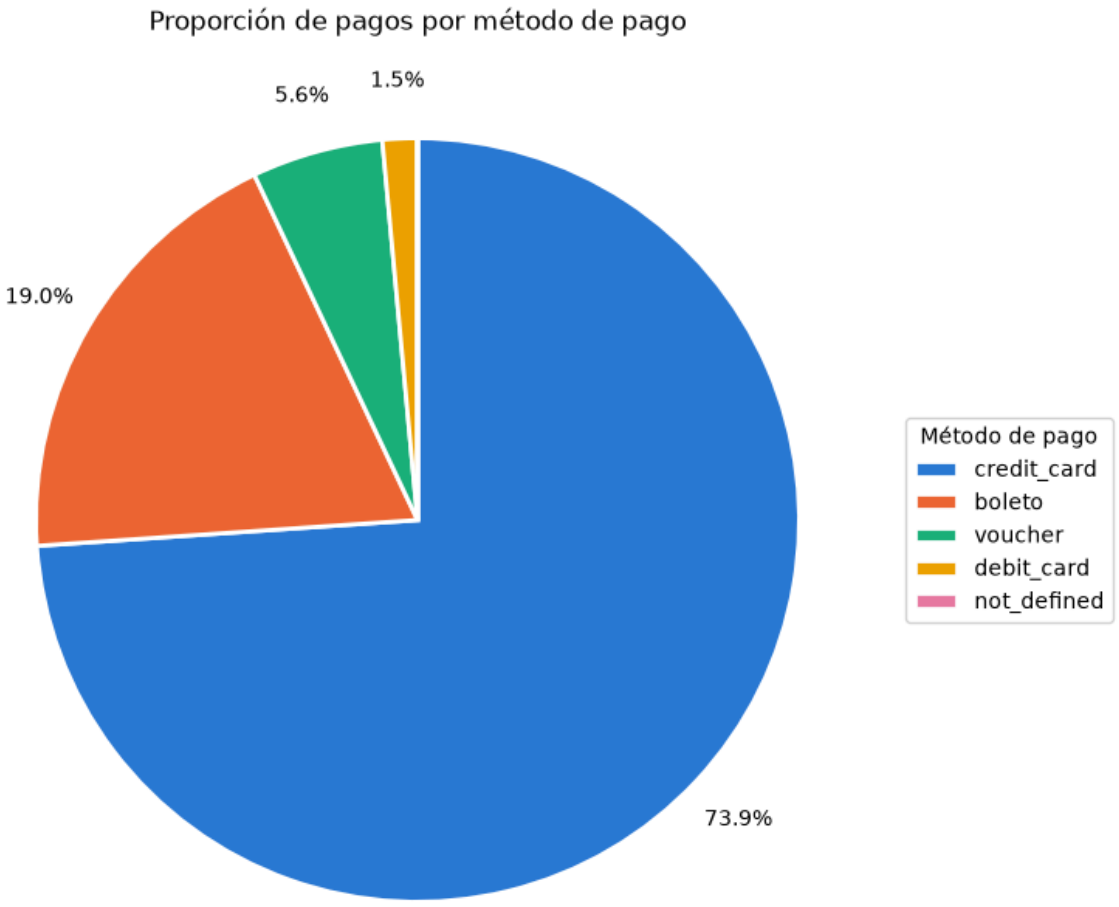
In [53]:
```
def mostrar_porcentaje_si_es_visible(porcentaje):
    if porcentaje < 1:
        return ""
    return f"{porcentaje:.1f}%"
```

In [54]:
```
fig, ax = plt.subplots(figsize=(8, 8))

ax.pie(
    cantidad_pagos_por_metodo.values,
    autopct=mostrar_porcentaje_si_es_visible,
    pctdistance=1.15,
    colors=colores_metodos_pago,
    startangle=90,
    counterclock=False,
    wedgeprops={"edgecolor": "white", "linewidth": 2}
)

ax.legend(cantidad_pagos_por_metodo.index, title="Método de pago", loc="center left", bbox_to_anchor=(1, 0.5))
ax.set_title("Proporción de pagos por método de pago")

plt.show()
```



## Reflexión

**¿Cuál de las dos gráficas permite comparar mejor los métodos de pago?** La gráfica de barras. Todas las barras empiezan en cero y comparamos alturas, así es fácil ver cuánto más grande es un método que otro.

**¿Cuál utilizarías si quisieras enfatizar la proporción que representa cada método?** El pie chart, porque muestra cada método como una parte del total (100%) y deja muy claro que la tarjeta de crédito ocupa casi tres cuartas partes de todos los pagos.

---

# Ejercicio 7: Número de cuotas

**Pregunta:** ¿Qué número de cuotas es el más frecuente?

In [55]:
```
cantidad_pagos_por_cuotas = order_payments.groupby("payment_installments")
["order_id"].count()
cantidad_pagos_por_cuotas
```

Out[55]:
```
payment_installments
0         2
1     52546
2     12413
3     10461
4      7098
5      5239
6      3920
7      1626
8      4268
9       644
10     5328
11       23
12      133
13       16
14       15
15       74
16        5
17        8
18       27
20       17
21        3
22        1
23        1
24       18
Name: order_id, dtype: int64
```

In [56]:
```
numero_cuotas_mas_frecuente = cantidad_pagos_por_cuotas.idxmax()
print("Número de cuotas más frecuente:", numero_cuotas_mas_frecuente)
print("Pagos con ese número de cuotas:", cantidad_pagos_por_cuotas.max())
```

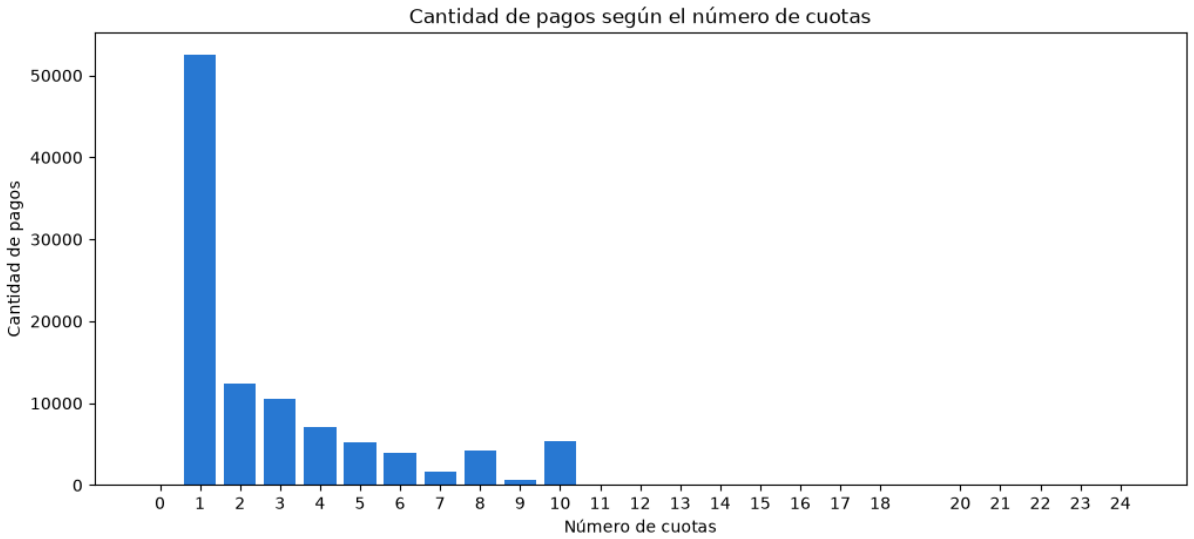
```
Número de cuotas más frecuente: 1
Pagos con ese número de cuotas: 52546
```

In [57]:
```
fig, ax = plt.subplots(figsize=(12, 5))

ax.bar(cantidad_pagos_por_cuotas.index, cantidad_pagos_por_cuotas.values,
color=color_barras)

ax.set_title("Cantidad de pagos según el número de cuotas")
ax.set_xlabel("Número de cuotas")
ax.set_ylabel("Cantidad de pagos")
plt.xticks(cantidad_pagos_por_cuotas.index)

plt.show()
```



## Reto: solo de 1 a 10 cuotas

In [58]:
```
pagos_de_1_a_10_cuotas = order_payments[(order_payments["payment_installments"]
>= 1) & (order_payments["payment_installments"] <= 10)]

cantidad_pagos_de_1_a_10_cuotas =
pagos_de_1_a_10_cuotas.groupby("payment_installments")["order_id"].count()
cantidad_pagos_de_1_a_10_cuotas
```

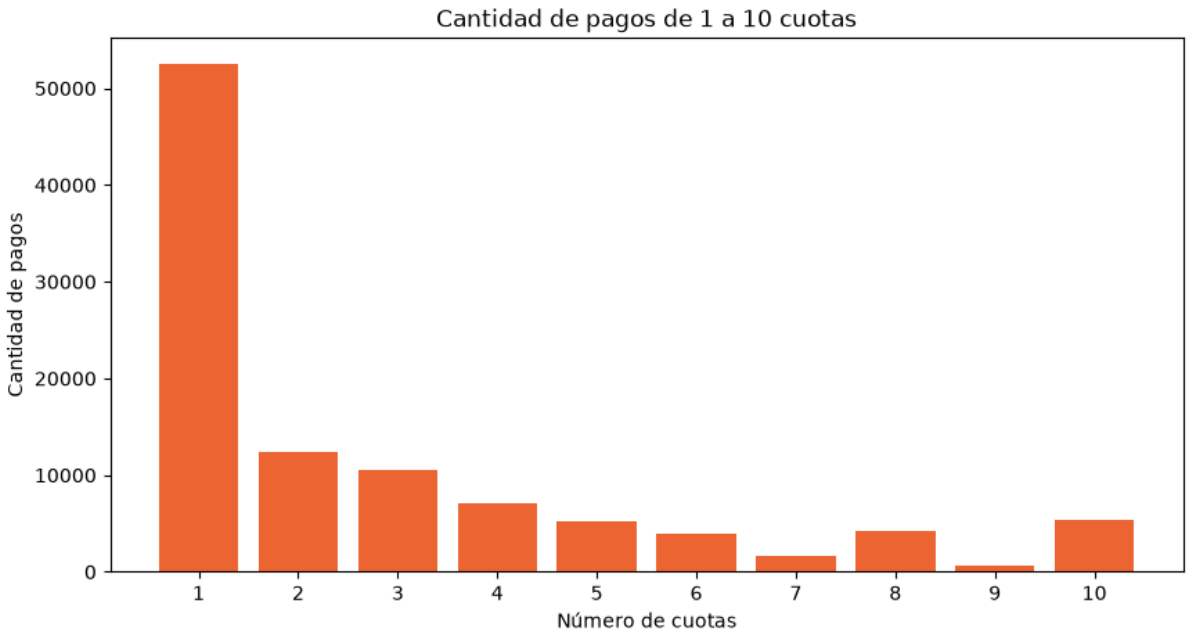
Out[58]:
```
payment_installments
1     52546
2     12413
3     10461
4      7098
5      5239
6      3920
7      1626
8      4268
9       644
10     5328
Name: order_id, dtype: int64
```

In [59]:
```
fig, ax = plt.subplots(figsize=(10, 5))

ax.bar(cantidad_pagos_de_1_a_10_cuotas.index,
cantidad_pagos_de_1_a_10_cuotas.values, color=color_barras_secundario)

ax.set_title("Cantidad de pagos de 1 a 10 cuotas")
ax.set_xlabel("Número de cuotas")
ax.set_ylabel("Cantidad de pagos")
plt.xticks(range(1, 11))

plt.show()
```



---

## Ejercicio 8: Comparando visualizaciones

**Pregunta:** ¿Cuál utilizarías en un reporte para comparar los métodos de pago? ¿Y cuál para enfatizar la proporción de cada método?

- **Variable:** `payment_type`.
- **Operación:** usamos exactamente el mismo conteo del ejercicio 6 (`cantidad_pagos_por_metodo`), así las dos gráficas representan los mismos datos.
- **Gráfica:** barras y pie chart, una junto a la otra. Cada método tiene el mismo color en las dos gráficas.

In [60]:
```
cantidad_pagos_por_metodo
```

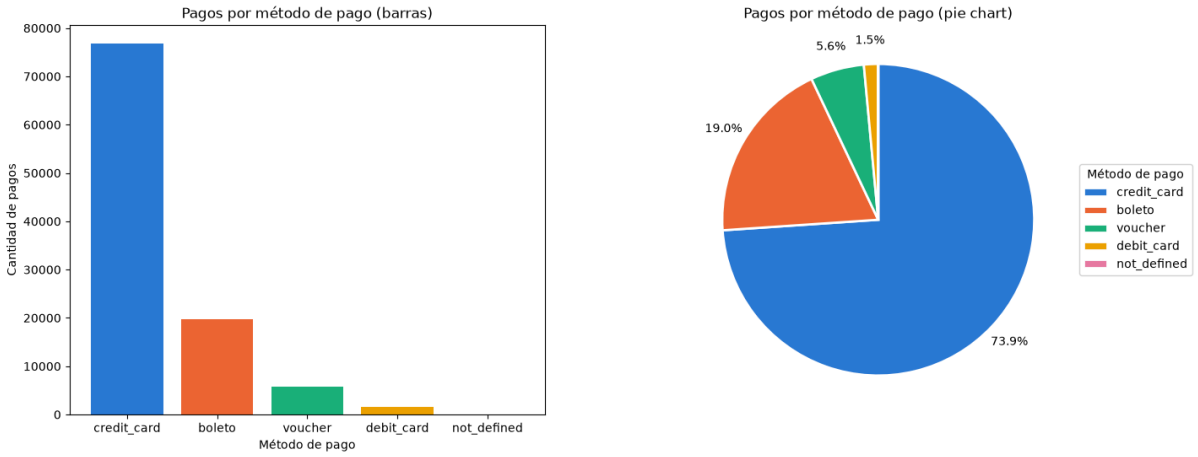
Out[60]:
```
payment_type
credit_card    76795
boleto         19784
voucher         5775
debit_card      1529
not_defined        3
Name: count, dtype: int64
```

In [61]:
```
fig, (ax_barras, ax_pie) = plt.subplots(1, 2, figsize=(16, 6))

ax_barras.bar(cantidad_pagos_por_metodo.index, cantidad_pagos_por_metodo.values,
color=colores_metodos_pago)
ax_barras.set_title("Pagos por método de pago (barras)")
ax_barras.set_xlabel("Método de pago")
ax_barras.set_ylabel("Cantidad de pagos")

ax_pie.pie(
    cantidad_pagos_por_metodo.values,
    autopct=mostrar_porcentaje_si_es_visible,
    pctdistance=1.15,
    colors=colores_metodos_pago,
    startangle=90,
    counterclock=False,
    wedgeprops={"edgecolor": "white", "linewidth": 2}
)
ax_pie.legend(cantidad_pagos_por_metodo.index, title="Método de pago",
loc="center left", bbox_to_anchor=(1, 0.5))
ax_pie.set_title("Pagos por método de pago (pie chart)")

plt.show()
```




---

# Reto de personalización

- Un color diferente para cada barra (los mismos colores del ejercicio 8).
- La cantidad escrita encima de cada barra con `ax.bar_label`.
- Título más grande y en negritas.
- Una cuadrícula suave en el eje Y y sin los bordes de arriba y de la derecha.

In [62]:
```
fig, ax = plt.subplots(figsize=(10, 6))

barras_metodos_pago = ax.bar(cantidad_pagos_por_metodo.index,
cantidad_pagos_por_metodo.values, color=colores_metodos_pago)
ax.bar_label(barras_metodos_pago, padding=3)

ax.set_title("¿Cómo pagan los clientes de Olist?", fontsize=15,
fontweight="bold")
ax.set_xlabel("Método de pago", fontsize=11)
ax.set_ylabel("Cantidad de pagos", fontsize=11)

ax.grid(axis="y", color="#e1e0d9")
ax.set_axisbelow(True)
ax.spines["top"].set_visible(False)
ax.spines["right"].set_visible(False)
plt.xticks(fontsize=11)

plt.show()
```

